# UAV 農作物画像における Depth Anything V2 Small の Metric Depth 適応と局所深度構造の評価

著者名・所属：提出前に記入

2026 年 10 月 14 日

# 要旨

農作物の生育状態を広域・反復的に把握する手段として UAV 画像と深度推定を組み合わせた計測が期待される。しかし単眼モデルのカメラ座標系深度は、地表から植物頂部までの垂直距離である草丈とは異なる。本研究では Depth Anything V2 Small を UAV3DCrop の Corn、Oat、Wheat、Soybean 画像へ適応した第 1〜3 回実験を再整理し、絶対深度誤差と局所深度構造を別々に評価した。学習 384 組（Day019、028、040）、検証 128 組（Day047）を用い、独立 test319 組および過去 52 組は未使用とした。モデル A は Relative Small 由来 backbone に新規 Metric head を設け 1 epoch 学習、B は未学習 Metric Outdoor Small、C は同モデルを 1 epoch 追加学習、D は元の Metric Outdoor Small から独立した 20 epoch 計画 run を開始し epoch 5 まで学習した。共通 validation の RMSE は B の 14.5340 m から C の 1.7490 m、D epoch 5 の 1.0094 m へ低下した。D epoch 5 は MAE 0.7373 m、AbsRel 0.03694、Pearson 0.9919、14 px 局所差 MAE 0.06148 m であった。一方、GT 差 20 cm 以上の標本では振幅比 0.3304、符号一致率 81.02% で、大きな変化の過小推定が残った。第 2 回分析では A の局所誤差増加が画像端 128 px 以内に集中し、同帯は標本ペア 10.90% で A−B 局所 MAE 増分の 82.52% を占めた。局所変化ゼロの基準が総局所 MAE に有利となり得ることも確認した。結果はカメラ Z-depth に対するもので、垂直草丈や稲高を実証しない。独立 test、複数 seed、稲高 GT は今後の課題である。**キーワード：**単眼深度推定，Metric Depth，UAV，局所深度差，草丈

# 目次

要旨 i

第 1 章 序論 1

1.1 背景 . . . . . 1

1.2 目的と貢献 . . . . . 1

第 2 章 関連研究と理論 2

2.1 単眼深度推定 . . . . . 2

2.2 Depth Anything V2、ViT、DPT . . . . . 2

2.3 転移学習と SiLog . . . . . 2

2.4 写真測量深度と植物高 . . . . . 3

第 3 章 データセットと前処理 4

3.1 対象データと分割 . . . . . 4

3.2 GT と前処理 . . . . . 4

3.3 深度と草丈の違い . . . . . 5

第 4 章 学習手法 6

4.1 比較モデル . . . . . 6

4.2 forward と有効 GT . . . . . 6

4.3 学習条件と scheduler . . . . . 7

4.4 checkpoint 管理 . . . . . 7

第 5 章 評価方法 8

5.1 絶対深度指標 . . . . . 8

5.2 局所深度差指標 . . . . . 8

5.3 全ペア・固定標本・基準値 . . . . . 9

5.4 境界と統計単位 . . . . . 9

第 6 章 実験結果 10
6.1 モデル A–D の主比較 . . . . . 10
6.2 第 3 回 epoch 別推移 . . . . . 10
6.3 GT 差 20 cm 以上の局所構造 . . . . . 11
6.4 画像端と画像内部 . . . . . 13
6.5 作物・撮影方向別 . . . . . 13
6.6 checkpoint 選択 . . . . . 14

第 7 章 考察 15
7.1 Metric Outdoor 事前学習からの適応 . . . . . 15
7.2 絶対深度と局所形状の非同値性 . . . . . 15
7.3 ゼロ差分基準の含意 . . . . . 15
7.4 Relative 由来 A の画像端偽勾配 . . . . . 16
7.5 518 px 入力と写真測量 GT . . . . . 16
7.6 Oblique 画像、作物差、稲高 . . . . . 16

第 8 章 限界と今後の課題 17
8.1 限界 . . . . . 17
8.2 次の検証候補 . . . . . 17

第 9 章 結論 19

付録 A 再現性・根拠資料 20
A.1 実験条件と環境 . . . . . 20
A.2 データ・コード・成果物の保管先 . . . . . 21
A.3 図表の作成根拠 . . . . . 22
A.4 ファイル整合性 . . . . . 22

参考文献 24

# 図目次

6.1 第 3 回モデル D の epoch 曲線。既存 epoch CSV の数値から再描画した。RMSE/AbsRel は全 validation 画素、Δ-MAE は全有効 14 px ペア、振幅比・符号一致は GT 差 20 cm 以上の固定標本である。縦軸範囲は指標ごとに異なる。 . 11
6.2 第 2 回の GT 差分階級ごとの局所深度差 MAE。各値は報告済み固定標本。小差分の多数ペアと 20 cm 以上のペアでモデル順位が異なる。 . . . . . 12
6.3 第 2 回固定標本における画像端距離別 14 px 局所差 MAE。端 0–128 px 帯はペアの 10.90% だが、A の誤差が突出する。 . . . . . 13
6.4 モデル A–D の validation 比較。左は全有効画素 RMSE、右は全有効 14 px ペア局所 MAE。破線は第 2 回ゼロ差分基準 0.06421 m。 . . . . . 14

# 表目次


3.1 実験で使用した分割 . . . . . 4

6.1 共通 validation における主要モデル比較 . . . . . 10
6.2 モデル D の epoch 別 validation 結果 . . . . . 10
6.3 モデル D epoch 5 の作物別結果 . . . . . 13
6.4 モデル D epoch 5 の撮影方向別結果 . . . . . 14

A.1 実験条件と記録状態 . . . . . 20
A.2 主要根拠ファイルと所在 . . . . . 21

# 第 1 章

# 序論

## 1.1　背景

作物の草丈は生育段階、栄養状態、倒伏リスク、収量形成などを把握する重要な表現型である。定規等による地上計測は直接的である一方、多数個体を反復して測るには労力がかかる。UAV 画像は広域を短時間で取得でき、画像処理や写真測量と組み合わせた高スループットな表現型計測を可能にする。UAV 画像・LiDAR を用いた作物高推定は、作物、撮影時期、地面モデル、視線・スキャン角度に依存することが報告されている [8, 7]。単眼深度推定は一枚の RGB 画像から各画素の奥行きを推定するため、追加深度センサを必要としない。視覚基盤モデルの特徴を下流タスクへ転移することで、単眼深度推定にも適応が可能となった [4, 5]。ただし単眼画像から尺度を一意に定めることは原理的に困難であり、学習分布や幾何的手がかりに依存する [1]。屋外一般シーンで学習された Metric Depth モデルは、葉群、細い茎、列状植生、露出土壌、遮蔽が混在する農作物画像で尺度誤差や局所平滑化を生じ得る。

## 1.2　目的と貢献

本研究は Depth Anything V2 Small の Metric Depth 出力を農作物 UAV 画像に適応し、絶対深度精度と局所深度変化がどのように推移するかを既実施 3 実験から検討する。貢献は、(1) Relative 由来 Metric head、未学習 Metric Outdoor、1 epoch 追加学習、独立した 5 epoch run を共通 validation の定義に注意して統合すること、(2) 局所差分の振幅・符号・GT 差分階級・画像端の詳細分析から全体局所 MAE の限界を示すこと、(3) epoch 1–5 曲線から絶対値と局所形状の非同値性、再現性、未検証事項を記録することである。本稿は実施済み実験の中間報告であり、稲の垂直草丈または独立 test 性能を報告するものではない。

# 第 2 章

# 関連研究と理論

## 2.1　単眼深度推定

単眼画像 $I$ から深度場 $D$ を求める問題は画素ごとの回帰 $D = f_\theta(I)$ として表される。単眼投影では物体の大きさと距離の組合せが同じ画像を生じ得るため、尺度は画像内容のみから常に一意ではない。Relative Depth は主に前後関係や相対構造を表し、Metric Depth はメートル等の実尺度を出力する。Relative checkpoint を Metric 推定へ転用するには、尺度を学ぶ head と Metric 教師が必要である。

## 2.2　Depth Anything V2、ViT、DPT

Depth Anything V2 は大規模な合成深度教師と実画像擬似ラベルを組み合わせた単眼深度モデルであり、複数規模のモデルと屋内・屋外 Metric checkpoint が公開されている [5]。Small は DINOv2 ViT-S/14 系 encoder から得る中間特徴を用いる [4]。Vision Transformer（ViT）は画像を patch token 列へ写像し、Self-Attention により文脈特徴を学習する [2]。Dense Prediction Transformer（DPT）は異なる Transformer 層の特徴を解像度別のマップへ射影し、融合ブロックで段階的に統合して密な画素予測を行う [3]。したがって出力は単一 patch の分類ではなく、encoder 特徴と decoder 再構成の組合せである。Metric Depth 実装は head 出力を sigmoid で $[0, 1]$ へ写像し、モデル上限 $M$ でスケールする。本研究では GT マスク上限と forward 係数を別パラメータにした。$M$ は予測可能深度範囲、$G$ は loss・評価で採用する GT 画素範囲である。

## 2.3　転移学習と SiLog

事前学習特徴を新しい分布へ適応する転移学習として、本研究は Relative backbone から Metric head を学ぶ A と、Metric Outdoor 全体を追加更新する C/D を比較した。尺度不変対数損失（SiLog）は $g_i = \log \hat{d}_i - \log d_i$ に基づき、対数誤差の二乗平均から共通対数尺度偏差成分を控除す

る [1]。

$$L_{\mathrm{SiLog}} = \sqrt{\frac{1}{N}\sum_{i=1}^{N} g_i^2 - \lambda \left(\frac{1}{N}\sum_{i=1}^{N} g_i\right)^2}, \quad \lambda = 0.5.$$

この構成は相対的な誤差と尺度バイアスを同時に扱うが、14 px 差分を直接最小化する損失ではない。本稿の学習では SiLog を変更していない。

## 2.4 写真測量深度と植物高

UAV3DCrop は反復・複数視点 UAV 画像と写真測量由来幾何情報を含むベンチマークである [7]。本研究の GT はカメラ座標系の光軸方向 Z-depth であり、世界座標系の鉛直軸高さではない。草丈の計算には植物頂部と地面の対応、カメラ姿勢・内部標定、座標変換が必要である。よって本研究の深度差分は植物垂直高差の教師ではない。

# 第 3 章

# データセットと前処理

## 3.1　対象データと分割

UAV3DCrop の Corn、Oat、Wheat、Soybean から、RGB と対応深度 GT の 512 組、計 1024 ファイルを使用した。記録された転送量は 7,850,330,776 byte である。データは第 1 回実験時に Google Drive へ保存され、第 2・3 回で再利用された。本報告書作成時にデータは再取得・再監査していない。

表3.1: 実験で使用した分割

| 用途 | 撮影日 | 組数 | 使用 |
|---|---|---|---|
| 学習 | Day019, Day028, Day040 | 384 | 学習 |
| 検証 | Day047 | 128 | 各 run の validation |
| 独立 test | 未取得 | 319 | 未使用 |
| 過去評価 | 過去の 52 組 | 52 | モデル選択に未使用 |

撮影日単位で分割し、同じ日の類似画像が train/validation 間へ混在するリスクを抑えた。ただし、未知日・未知圃場への汎化を保証するものではない。独立 test はモデル選択完了まで未使用に保留された。

## 3.2　GT と前処理

RGB と深度は元解像度 3956×5280 pixel で管理された。train GT 最大値は 62.15625 m、99.9 percentile は 52.90625 m である。train 最大値を包含する教師・評価上限として $G = 65$ m を設定した。これは validation/test による選択ではない。無効値は 0 で、GT が有限かつ正かつ 65 m 以下の画素だけを有効とした。学習は 518×518 crop を入力とする。検証はアスペクト比を保持

して短辺 518、長辺約 686 pixel へ resize し、予測を元サイズへ復元して評価した。元短辺 3956 pixel から 518 への倍率は約 7.64 であり、元画像 14 pixel 間隔はモデル入力上約 1.83 pixel となる。ViT の 14 pixel patch を目安とすると元画像上約 107 pixel に対応する。DPT は多解像度特徴を融合するものの、縮小で葉・茎・株境界の情報が弱まる可能性がある。

## 3.3　深度と草丈の違い

GT Z はカメラ光軸方向に沿う距離である。Oblique では地面平面も画像内で奥行き変化をもつ。カメラ俯角のある鉛直植物は、見かけの Z 変化が高さと単純比例しない。草丈評価には共通世界座標で地面と頂部を対応づけ、鉛直成分を計算する必要がある。したがって 20 cm の Z 差は垂直草丈 20 cm を意味しない。

# 第 4 章

# 学習手法

## 4.1　比較モデル

全モデルは Depth Anything V2 Small 系 ViT-S/14 encoder と DPT 型密予測 head を基礎とする [5, 3]。

モデル A
: Relative Small backbone を転用し、Metric neck/head を新規初期化して 1 epoch 学習。model output cap は 65 m。

モデル B
: 追加学習前の Metric Outdoor Small。output cap 80 m。

モデル C
: Metric Outdoor Small 重みから 1 epoch 追加学習した第 2 回モデル。cap 80 m。

モデル D
: 元の未追加学習 Metric Outdoor Small から独立 run として開始した第 3 回モデル。20 epoch 計画で epoch 5 まで実行。C の checkpoint から継続していない。cap 80 m。

A は初期化方式だけでなく出力上限も B–D と異なるため、上限の寄与を単独で分離した比較ではない。全モデルの GT mask は $G = 65$ m で共通とし、B–D 予測を 65 m に再スケールまたは clip していない。

## 4.2　forward と有効 GT

head 未正規化出力を $z_\theta(I)$ とすると

$$\hat{d}(I) = M\sigma(z_\theta(I)), \qquad \mathcal{V} = \{i : d_i^* > 0,\ d_i^* \le G,\ d_i^* \text{ finite}\}, \quad G = 65 \text{ m}.$$

$M$ は forward 出力係数、$G$ は loss・評価に使う GT 上限である。これらを同じ設定値にすると、出力範囲を 65 m に変えただけで同一 weight の予測が 80 m 時の 65/80 倍へ変化する。第 2 回の実画像 probe でこの現象を確認したため、コードで分離した。

## 4.3 学習条件と scheduler

基準 run は SiLog、AdamW[6]、seed 42、batch 1、gradient accumulation 4、AMP を用いた。encoder LR $5 \times 10^{-6}$、neck/head LR $5 \times 10^{-5}$ である。384 画像・batch 1 は 1 epoch 96 planned optimizer updates、20 epoch 計画は 1920 update となる。D の PolynomialLR 総期間は 1920 update のまま維持された。AMP skip 時は optimizer update・scheduler を進めない。epoch 1 に skip が 1 回あり、epoch 5 時点 scheduler は成功 update 479 回に対応する。C の 1 epoch run と D では総 scheduler 期間と履歴が異なり、両者の差を epoch 数だけの因果効果とみなさない。

## 4.4 checkpoint 管理

各 epoch 境界で model、optimizer、scheduler、GradScaler、乱数状態を含む checkpoint と metadata を保存した。第 3 回は epoch 0–5 complete checkpoint、run metadata、status、epoch metrics CSV/JSON、training log、sync receipt を Drive へ保存した。今回の論文作成中に checkpoint の再読み込みや再推論はしていない。D は 5/20 epoch で安全停止中である。

# 第 5 章

# 評価方法

## 5.1　絶対深度指標

有効画素数を $N$、予測深度を $\hat{d}_i$、GT を $d_i$ とする。平均絶対誤差、二乗平均平方根誤差、絶対相対誤差は

$$\mathrm{MAE} = \frac{1}{N}\sum_i |\hat{d}_i - d_i|, \quad \mathrm{RMSE} = \sqrt{\frac{1}{N}\sum_i (\hat{d}_i - d_i)^2}, \quad \mathrm{AbsRel} = \frac{1}{N}\sum_i \frac{|\hat{d}_i - d_i|}{d_i}$$

である。RMSE は大誤差を二乗で重みづけ、AbsRel は GT 距離に対する誤差比を表す。Pearson 相関 $r$ は有効画素上の予測と GT の線形相関であり、尺度バイアス自体を測らないため絶対誤差と併記した。深度 MAE 等は元解像度へ復元後の全 validation 画素集計である。

## 5.2　局所深度差指標

元画像座標で水平方向または垂直方向に 14 pixel 離れた有効画素対 $(i, j)$ について、

$$\Delta d_{ij} = d_j - d_i, \quad \Delta\hat{d}_{ij} = \hat{d}_j - \hat{d}_i, \quad E_\Delta = \frac{1}{P}\sum_{(i,j)} |\Delta\hat{d}_{ij} - \Delta d_{ij}|$$

を 14 px 局所深度差 MAE とした。ペア両端が GT 有効 mask 内にあるものを採用する。これは画素深度の絶対誤差ではなく差分誤差である。GT 絶対差分が 20 cm 以上の固定標本に対して、差分振幅比を

$$R_{\mathrm{amp}} = \frac{\mathrm{mean}\,|\Delta\hat{d}|}{\mathrm{mean}\,|\Delta d|}$$

と定義した。比が 1 未満なら平均振幅を過小推定する。符号一致率は GT 差分非ゼロのペアで $\mathrm{sign}(\Delta\hat{d}) = \mathrm{sign}(\Delta d)$ となる割合で、予測 0 は不一致とする。差分相関は $\Delta d, \Delta\hat{d}$ の Pearson 相関、回帰傾きは切片を含む最小二乗回帰 $\Delta\hat{d} = a + b\Delta d + \epsilon$ の $b$ である。回帰で予測を補正していない。

## 5.3　全ペア・固定標本・基準値

絶対深度と 14 px 局所 MAE は全有効画素・全有効ペアで計算した。GT 差分階級、符号、振幅・相関・回帰、画像端帯は固定座標標本による詳細集計である。第 2 回の 14 px 固定標本は 25,552,938 pair と報告され、候補座標はモデル共通、seed 規則が保存された。標本値を全ペア値と混同しない。第 3 回 CSV は full-pair 列と sampled 列を分けるが、固定標本数が報告資料で照合できない項目は本稿で 25,552,938 と仮定しない。局所変化を常に 0 とする基準では $\Delta\hat{d} = 0$ となり、局所 MAE は GT ペアの平均絶対差分である。このゼロ差分基準は絶対深度 MAE/RMSE を定義しない。第 2 回の全 14 px ペア値は 0.06421224 m であった。GT 差分が小さいペアが多いと平坦予測が総合局所 MAE で有利になり得る。

## 5.4　境界と統計単位

画像端からの最短距離で 0–128 px、128–512 px、512 px 以上に分類した。主指標は全画面評価のままであり、端除外値は診断である。validation 128 画像内の画素・ペアは空間自己相関をもつ。数十億画素を独立標本として信頼区間や有意差検定を行っていない。画像単位の再標本化に必要な統一画像単位集計を根拠一式から確認できないため、信頼区間・有意差を報告しない。

# 第 6 章

# 実験結果

## 6.1　モデル A–D の主比較

表6.1は共通 validation の確定済み結果である。A/B は第 1 回、C は第 2 回、D は第 3 回 epoch 5 である。絶対指標は有効画素、local14 は全有効ペアで集計した。

表6.1: 共通 validation における主要モデル比較

| モデル | epoch | MAE m | RMSE m | AbsRel | Pearson $r$ | local14 MAE m |
|---|---|---|---|---|---|---|
| A Relative 由来 Metric | 1 | 2.4897 | 3.9063 | .12120 | .8712 | .10545 |
| B 未学習 Metric Outdoor | 0 | 13.2730 | 14.5340 | .65896 | .7848 | .06561 |
| C Metric Outdoor 追加学習 | 1 | 1.1324 | 1.7490 | .05208 | .9773 | .06800 |
| D Metric Outdoor 独立 run | 5 | .7373 | 1.0094 | .03694 | .9919 | .06148 |

B の局所差 MAE が C より僅かに低いことだけで形状復元が優れるとは言えない。第 2 回ゼロ差分基準 0.06421 m に対し B は 0.06561 m、C は 0.06800 m である。D は全ペア local14 が 0.06148 m となり、この基準を下回った。

## 6.2　第 3 回 epoch 別推移

表6.2は Drive の第 3 回 epoch CSV と報告表の値である。GT 差 20 cm 以上の局所 MAE、振幅比、符号、画像端・内部は固定標本、local14 は全有効ペア指標である。

表6.2: モデル D の epoch 別 validation 結果

| Ep. | SiLog | MAE | RMSE | AbsRel | $r$ | local14 | GT≥20cm MAE | 振幅比 | 符号 | 秒 |
|---|---|---|---|---|---|---|---|---|---|---|
| 1 | .10622 | 1.0791 | 1.6299 | .05088 | .9805 | .06537 | .35276 | .3046 | 78.28% | 1085.5 |
| 2 | .05288 | 1.7002 | 1.9953 | .08907 | .9884 | .06339 | .34543 | .3263 | 80.24% | 1044.1 |
| 3 | .03596 | 1.0492 | 1.3334 | .05726 | .9894 | .06299 | .34708 | .3228 | 80.82% | 1097.8 |
| 4 | .03025 | .7744 | 1.0562 | .03913 | .9901 | .06237 | .34495 | .3428 | 80.52% | 1024.4 |
| 5 | .02794 | .7373 | 1.0094 | .03694 | .9919 | .06148 | .34090 | .3304 | 81.02% | 1020.9 |

MAE/RMSE/GT 局所 MAE/local14 は m、振幅比・損失は無次元、Pearson は $r$ である。各 epoch の VRAM peak は allocated 0.877 GiB、reserved 1.248 GiB。AMP skip は epoch 1 が 1 回、epoch 2–5 は 0 回。

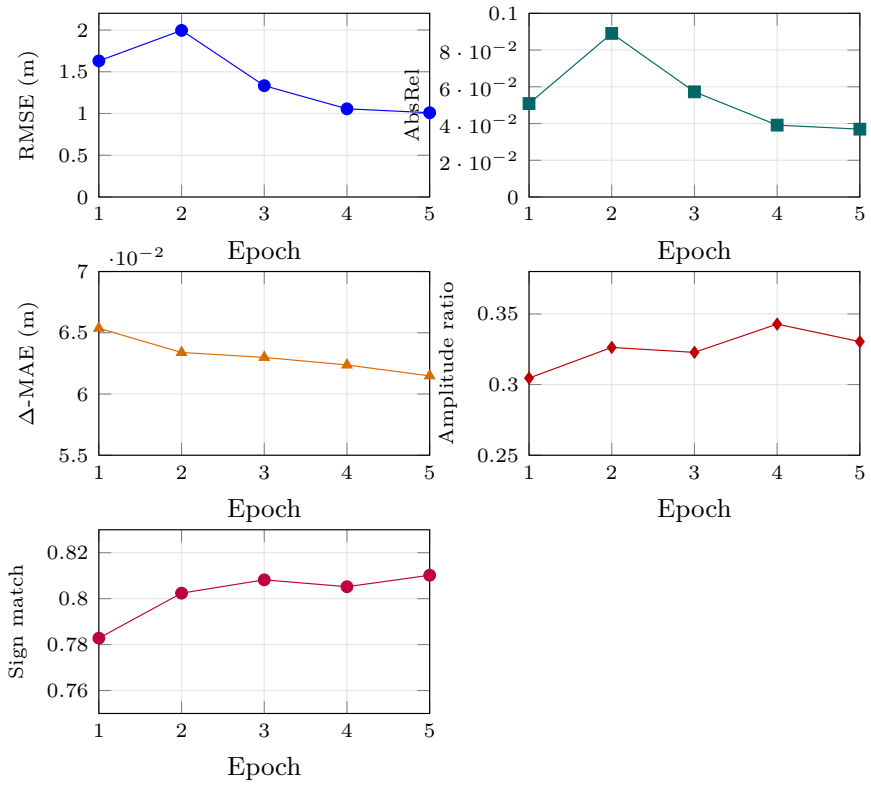



図6.1: 第 3 回モデル D の epoch 曲線。既存 epoch CSV の数値から再描画した。RMSE/AbsRel は全 validation 画素、Δ-MAE は全有効 14 px ペア、振幅比・符号一致は GT 差 20 cm 以上の固定標本である。縦軸範囲は指標ごとに異なる。

epoch 2 では RMSE が 1.6299 m から 1.9953 m、MAE が 1.0791 m から 1.7002 m、AbsRel が 0.05088 から 0.08907 へ一時悪化した。一方 local14 は 0.06537 m から 0.06339 m へ改善し、振幅比・符号一致も上昇した。epoch 3–5 で絶対誤差は低下し、epoch 5 に最小値となった。複数指標は単調に同時改善していない。

## 6.3　GT 差 20 cm 以上の局所構造

第 2 回モデル C では、GT 差 20 cm 以上の標本平均絶対差分 0.44370 m、予測平均振幅約 0.1453 m、振幅比 0.327 であった。該当区間局所 MAE は 0.35423 m、符号一致 77.95% であり、86.72% のペアで振幅を過小推定した。第 3 回 D では epoch 1 から 5 へ振幅比 0.3046 から 0.3304、区間 MAE0.35276 m から 0.34090 m、符号一致 78.28% から 81.02% へ変化した。改善はあるが単調

ではない。C と D の振幅比の差は小さいが、標本抽出条件を厳密に突合できないため対応のある差分比較とは解釈しない。

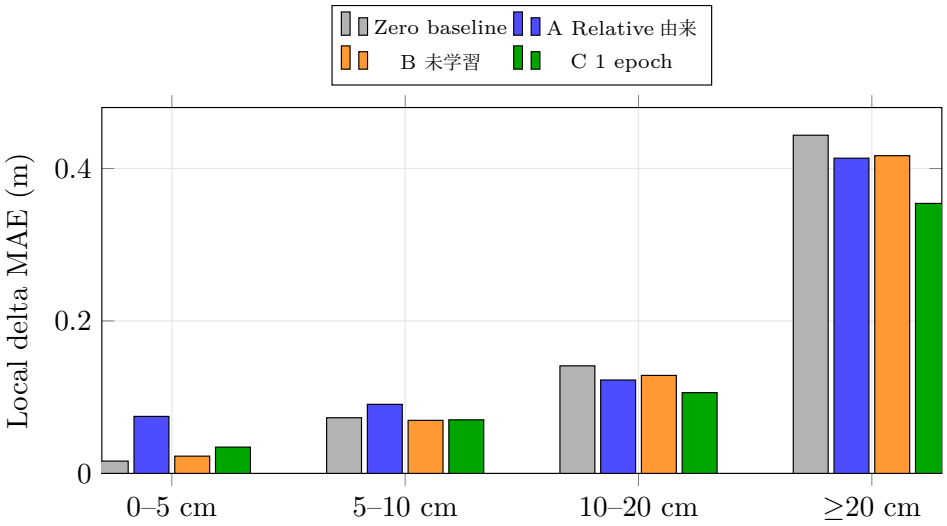



図6.2: 第 2 回の GT 差分階級ごとの局所深度差 MAE。各値は報告済み固定標本。小差分の多数ペアと 20 cm 以上のペアでモデル順位が異なる。

第 2 回 GT 差分階級標本の 72.96% は 0–5 cm であった。同階級の局所 MAE はゼロ基準 0.01617 m に対し A 0.07480 m、B 0.02266 m、C 0.03451 m である。20 cm 以上ではゼロ基準 0.44370 m、A 0.41357 m、B 0.41684 m、C 0.35423 m となり、C は大きい差分を小さくする誤差を相対的に減らした。

## 6.4　画像端と画像内部

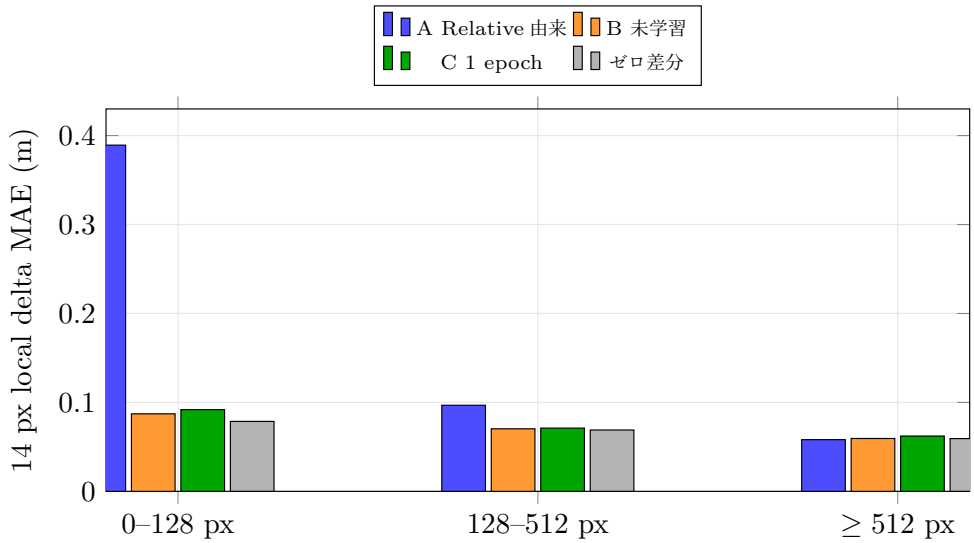



図6.3: 第 2 回固定標本における画像端距離別 14 px 局所差 MAE。端 0–128 px 帯はペアの 10.90% だが、A の誤差が突出する。

第 2 回標本の画像端 0–128 px では A 局所 MAE 0.38929 m、B 0.08717 m、C 0.09189 m であった。この帯のペア割合は 10.90% だが、A−B の総局所 MAE 増分の 82.52% を占めた。端から 512 px 以上の内部では A 0.05814 m、B 0.05945 m、C 0.06220 m となり順位が逆転する。D epoch 5 は端 0–128 px の sampled local MAE 0.08095 m、内部 512 px 以上 0.05678 m である。GT 差 20 cm 以上の D では端 MAE0.36135 m、振幅比 0.4951、符号 84.40%、内部 MAE0.35727 m、比 0.2028、符号 77.67% である。標本結果であり因果効果ではない。

## 6.5　作物・撮影方向別

表6.3: モデル D epoch 5 の作物別結果

| 作物 | MAE m | RMSE m | AbsRel | local14 MAE m |
|---|---|---|---|---|
| Corn | 1.00694 | 1.30455 | .04711 | .08305 |
| Oat | .89419 | 1.13390 | .04414 | .06255 |
| Soybean | .60541 | .86185 | .03249 | .04892 |
| Wheat | .44293 | .58861 | .02403 | .05142 |

表6.4: モデル D epoch 5 の撮影方向別結果

| 方向 | MAE m | RMSE m | AbsRel | Pearson $r$ | local14 MAE m |
|---|---|---|---|---|---|
| Nadir | .57857 | .75396 | .03704 | .79186 | .03649 |
| Oblique | .89654 | 1.21291 | .03684 | .99173 | .08657 |

Oblique は Nadir より MAE、RMSE、局所 14 MAE が大きい。Pearson の方向差は深度分布レンジや画像混合集計の影響を受けるため、単独で難易度を決めない。作物・方向・深度範囲が均衡化された要因実験ではないため、差を作物固有の原因へ帰属させない。

## 6.6 checkpoint 選択

第 3 回報告書では validation RMSE 最良は epoch 5（1.0094 m）、GT 差 20 cm 以上の標本局所 MAE 最良も epoch 5（0.34090 m）である。ただし振幅比は epoch 4 の 0.3428 が最高、符号一致と全 14 px MAE は epoch 5 が最良である。「局所形状最良」は単一の報告済み選択基準に限った呼称であり、総合最良を意味しない。独立 test は未使用である。

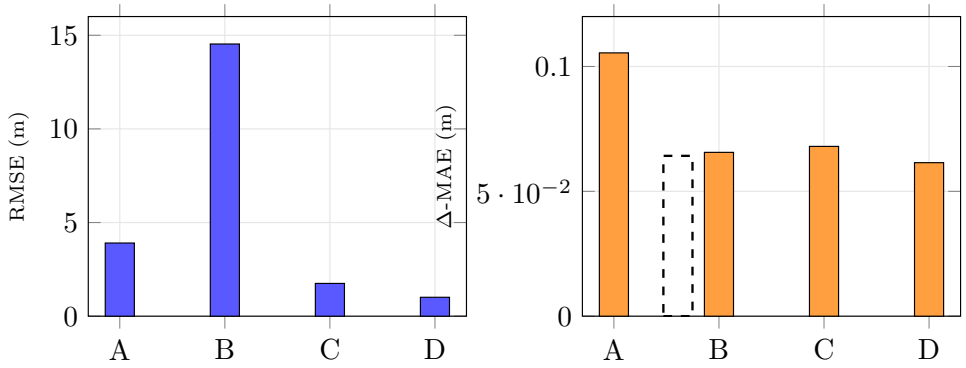



図6.4: モデル A–D の validation 比較。左は全有効画素 RMSE、右は全有効 14 px ペア局所 MAE。破線は第 2 回ゼロ差分基準 0.06421 m。

# 第 7 章

# 考察

## 7.1　Metric Outdoor 事前学習からの適応

B から C の MAE は 13.2730 m から 1.1324 m、RMSE は 14.5340 m から 1.7490 m、AbsRel は 0.65896 から 0.05208 へ低下した。B と C は Metric Outdoor 由来で出力 cap80 m を維持し、同じ Day047 validation と 65 m 以下の GT mask で比較されている。この validation において、1 epoch の農作物データ適応後に大きな絶対深度改善が観測されたと結論できる。D は同じ未学習 Metric Outdoor 初期値から独立に始め、epoch 5 の RMSE は 1.0094 m であった。ただし C と D は scheduler 総期間と run 履歴が異なるため、この差を純粋な epoch 数の効果とは断定しない。

## 7.2　絶対深度と局所形状の非同値性

SiLog は対数深度残差を通して深度場を最適化するが、14 px 差分誤差を直接最小化する目的ではない。絶対値や低周波構造が合っても、葉縁等の高周波形状は平滑化され得る。D の全 14 px MAE は epoch 1–5 で 0.06537 から 0.06148 m へ改善した一方、GT 差 20 cm 以上の振幅比は 0.3046–0.3428 で変動し、epoch 5 では 0.3304 であった。absolute depth 改善と局所振幅改善は同じ速度・方向ではない。epoch 2 は MAE/RMSE/AbsRel が epoch 1 より悪化したが、Pearson、局所 14 MAE、振幅比、符号一致は改善した。重み更新、validation 分布、最適化状態のどれが原因か保存ログからは特定できない。短い run における非単調推移として扱う。

## 7.3　ゼロ差分基準の含意

ゼロ差分基準 0.06421 m は、GT 差分が平坦なペアの多い 14 px 集計で、常に変化なしとする予測が小さい local MAE を得る場合を示す。B の振幅比は 0.3083 で、全局所 MAE0.06561 m もゼロ基準に近い。これは B の形状が忠実という証拠ではなく、評価平均が振幅縮小に利点を与えることと整合する。GT 差 0–5 cm が標本の 72.96% を占める一方、20 cm 以上は 7.48% である。

GT 階級、振幅、符号、相関、複数間隔を併記しなければ大きい構造の復元状態を見落とす。C は GT 差 20 cm 以上で B より MAE が小さく、符号一致も高いが、振幅比 0.327 は過小推定を示す。D epoch 5 も 0.3304 であり、課題は残る。第 2 回と第 3 回の標本抽出件数・抽出署名の完全な一致は根拠資料から照合できず、C と D の差を対応のある効果量として解釈しない。

## 7.4 Relative 由来 A の画像端偽勾配

第 2 回では初期 head 出力は約 32.50 m 近傍で平坦、学習後に端で強い空間差が見られ、Corn Nadir 例では GT がほぼ一定の路面に対して予測断面が約 29.5 m から 20 m へ傾く観察があった。これは画像端偽勾配という現象と整合する。しかし zero padding、学習 crop と検証時 landscape 形状の差、新 Metric head の学習不足、周辺文脈不足を個別に操作していないので、原因を確定できない。A の全画面局所 14 MAE は 0.10545 m で B/C より大きいが、端から 512 px 以上では A 0.05814 m、B 0.05945 m、C 0.06220 m となり順位が変わった。境界を除いた値は診断指標であり、主評価へ置き換えていない。A を全面的に形状不良とすることも内部値だけで優位とすることも適切でない。

## 7.5 518 px 入力と写真測量 GT

短辺 3956 から 518 px へ resize すると元 14 px は入力約 1.83 px となり、ViT-S/14 patch は元画像換算で約 107 px に相当する。DPT の multi-scale fusion が patch より小さい情報を完全に失うという意味ではないが、縮小・patch 化・復元補間が葉・茎境界を弱める可能性がある。第 2 回の GT 縮小・復元対照の 14 px MAE は 0.03117 m、相関 0.77472、回帰傾き 0.66885 であった。これは解像度変換で局所形状が変化し得る診断であり、モデル誤差の説明割合や厳密な誤差下限ではない。GT は写真測量再構成深度であり、地上実測値と同一ではない。遮蔽、対応点密度、再構成平滑化、位置合わせの不確かさを含み得る。孤立欠損近傍除外で主結果がほぼ変わらなかったことは、系統的な MVS 偏りや植生再構成誤差を否定しない。

## 7.6 Oblique 画像、作物差、稲高

D epoch 5 の Oblique は Nadir に比べ MAE/RMSE が高く、local14 は 0.08657 m 対 0.03649 m であった。斜め視で地面平面の深度勾配、葉群の自己遮蔽、列間の見え方、遠近、撮影配置等が影響し得るが、ここでは仮説である。方向別 Pearson が絶対指標の順位と異なることも深度レンジと混合集計を検討する必要性を示す。対象作物は Corn/Oat/Wheat/Soybean で、稲を含まない。GT もカメラ Z-depth で、植物頂部・地面の分割や地上座標鉛直高計算をしていない。したがってここでの結果は稲高精度を裏付けず、農作物画像への深度適応に関する予備的な結果に限る。

# 第 8 章

# 限界と今後の課題

## 8.1　限界

1. 第 3 回学習は総 20 epoch 計画の epoch 5 で停止し、epoch 6–20 は未実施である。SiLog 基準 run の収束・過学習は未確定である。
2. 無料 Colab GPU の利用制限により追加学習は停止した。追加課金や制限回避は行っていない。
3. validation は Day047 の 128 画像に限られ、未知撮影日・未知圃場への汎化は未検証である。
4. 複数 seed によるばらつきは未計測であり、画像単位信頼区間や有意差も報告していない。
5. independent test319 組は未取得・未使用、過去 52 組も学習・モデル選択には未使用である。
6. GT は写真測量由来カメラ Z-depth で地上実測値と同一ではない。地上垂直草丈 GT との比較はない。
7. 稲 UAV 画像および稲の垂直草丈 GT は未使用であり、稲高精度を実証していない。
8. 入力 518 px への縮小は微細構造を弱める可能性があるが、高解像度 tile との比較はしていない。

## 8.2　次の検証候補

第一に、保存済み D checkpoint から同じ 20 epoch scheduler、同一署名コード・分割を保って epoch 6–20 を再開する。epoch 毎に絶対深度と局所形状を記録する。epoch 5 で RMSE が改善中であることから残り epoch を完了すれば曲線の把握に価値はあるが、改善の継続は保証されない。第二に、SiLog 基準 run の評価後、新規別 run で局所差分損失を比較する。全画面 MAE/RMSE を保持しながら、GT 階級別振幅・符号・複数間隔を事前に定義する。基準 run へ損失変更を混ぜない。第三に重複 tile、高解像度入力、マルチスケール推論を比較する。GPU 前に無料 GPU 割当と VRAM を再計測する。第四に A の端要因を padding、crop 位置・アスペクト比、端損失寄与など個別変数として切り分けるが、端除外を主指標にしない。第五に稲画像、地面・頂部、カメラ

姿勢と地上実測高さを収集し、Z-depth から草丈へ変換する方法を検証する。モデル選択完了後に independent test を最終評価する。

# 第 9 章

# 結論

第 1〜3 回の実験から、同一 validation 上の Metric Outdoor Small は未学習 RMSE14.5340 m から 1 epoch 適応 C の 1.7490 m、独立 5 epoch run D の epoch 5 で 1.0094 m へ改善した。D epoch 5 の MAE は 0.7373 m、AbsRel は 0.03694、Pearson は 0.9919 で、絶対深度誤差と全 14 px 局所差 MAE は低下傾向にあった。epoch 2 では絶対誤差が一時増加し、複数指標が同じ方向に単調改善するとは限らなかった。局所高低差には課題が残る。C と D epoch 5 の GT 差 20 cm 以上の振幅比は報告値でいずれも約 0.33 であり、大きな差分の過小推定が残った。ただし run 間の詳細標本抽出条件を完全には照合できず、この近似値の小差を定量的な改善効果とは解釈しない。第 2 回では Relative 由来 A の局所誤差が画像端 128 px へ偏り、内部でモデル順位が変わった。ゼロ差分基準と GT 階級分析は、総局所 MAE が平坦予測に有利になり得ることを示した。確認済みなのは 4 作物の Day047 validation における Z-depth 結果である。稲垂直草丈、未知撮影日汎化、independent test、20 epoch 完了は未検証である。次段階では保存 checkpoint から基準 run を継続評価し、別 run の局所損失・高解像 tile 比較、地上実測高さを含む稲評価へ進む必要がある。

# 付録 A

# 再現性・根拠資料

## A.1　実験条件と環境

表A.1は各回の報告書、run metadata、学習 CSV から照合できた条件を示す。保存資料で確認できない環境情報は未記録とし、推測で補っていない。

表A.1: 実験条件と記録状態

| 項目 | 第 1・2 回 | 第 3 回（モデル D） |
|---|---|---|
| 対象 | UAV3DCrop Corn, Oat, Wheat, Soybean | 同左 |
| 分割 | train 384(Day019/028/040)、validation 128（Day047） | 同左、各 epoch で同じ split |
| 未使用データ | independent test 319 組、過去評価 52 組 | 同左 |
| 入力 | 518 px | 518 px |
| 初期化 | A: Relative Small backbone、新 Metric head。B: pretrained Outdoor。C: pretrained Outdoor | D: pretrained Metric Outdoor Small から独立 run |
| 出力上限 | A 65 m、B/C 80 m | 80 m |
| GT 評価上限 | 65 m | 65 m |
| 最適化 | AdamW、SiLog、seed 42。詳細は各実行報告を参照 | AdamW、encoder LR $5 \times 10^{-6}$、neck/head LR $5 \times 10^{-5}$、batch 1、accumulation 4、AMP |

| 項目 | 第 1・2 回 | 第 3 回（モデル D） |
|---|---|---|
| 学習計画 | A/C 各 1 epoch | D は 20 epoch 計画、epoch 1–5 完了 |
| scheduler | 実験ごとに異なる。C と D は同一条件ではない | PolynomialLR 1920 planned updates、96/epoch。epoch 5 で successful update 479 |
| GPU | Colab 無料 Tesla T4（第 1 回ログ） | Colab 無料 Tesla T4。peak allocated 0.877 GiB、reserved 1.248 GiB |
| 時間 | 第 2 回学習 +validation 約 12 分 05 秒 | D epoch 1–5 合計 5272.7 秒（約 1 時間 27 分 53 秒） |
| AMP skip | 第 2 回の optimizer 更新 skip 1 回 | D epoch 1 で 1 回、epoch 2–5 で 0 回 |
| ソフトウェア版 | 保存資料から全てを一意に確認できず | Python、PyTorch、CUDA/cuDNN 版は根拠資料で未記録 |

## A.2 データ・コード・成果物の保管先

研究データは Drive の `MyDrive/DepthAnythingV2-UAV/data/`に保存された 512 組を再利用した。転送量は 7,850,330,776 bytes である。本論文作成ではデータ再取得、GPU 推論、checkpoint 再ロードを行っていない。再現コードは第 3 回実験フォルダー内の `source_full_v1/`である。

表A.2: 主要根拠ファイルと所在

| 内容 | Drive 上の識別子・保存先 | 本稿での用途 |
|---|---|---|
| 第 1 回報告書 | file ID 1VMxUVF... | A/B 指標、split、学習条件 |
| 第 2 回最終報告書 | file ID 1ful2H... | C 指標、局所差・境界分析、ゼロ基準 |
| 第 2 回 shape summary | shape summary JSON | 階級・標本集計 |
| 第 2 回 shape groups | shape groups CSV | 詳細階級データ |
| 第 2 回境界分析 | border analysis JSON | 端・内部比較 |

| 内容 | Drive 上の識別子・保存先 | 本稿での用途 |
|---|---|---|
| 第 2 回図一覧 | analysis/figures folder | 既存 29 図。Corn Nadir 比較・overview へは代表比較図と overview |
| 第 3 回実験 folder | experiment folder | report、results、source、metadata |
| 第 3 回 run | run folder | checkpoint、status、metadata |
| epoch metrics CSV | epoch metrics CSV | 本稿添付 CSV と学習曲線の元データ |
| epoch metrics JSON | epoch metrics JSON | epoch・群別詳細値 |
| 第 3 回 run metadata | run metadata | 条件、run 識別 |
| 第 3 回学習ログ | training log | 実行経過・停止状態 |
| Drive 同期 receipt | sync receipt | 保存同期記録 |
| 第 3 回再現コード | source_full_v1 folder | 学習・評価実装 |
| 第 3 回 Notebook | Colab notebook | run Notebook |

## A.3　図表の作成根拠

本 PDF の図 1 は第 3 回 epoch CSV の 5 行からベクトル図として再描画した学習曲線である。図 2 は第 2 回報告書・shape summary の GT 差分階級集計、図 3 は第 2 回 border analysis と第 3 回 epoch CSV の端・内部値、図 4 は各回報告書の共通 validation 表から作成したモデル比較である。既存 PNG の転載ではなく、保存済みの数値を使って再描画した図である。第 2 回の元比較図 29 枚は上記 Drive folder に保存されている。

画素・ペアは画像内で空間依存するため、集計数を独立標本数と解釈していない。画像単位 bootstrap に必要な全モデル共通の画像別出力表は、確認した根拠資料には含まれないため、信頼区間および有意差検定は実施していない。

## A.4　ファイル整合性

第 3 回 epoch CSV は Drive から取得したファイルをパッケージへ複製し、内容を変更していない。ローカル複製の SHA256 は `9C19EC8C234015E451F9B7094DE4390C7DB31954A609007A831BFD9F22CF65AD` である。表・曲線の epoch 1–5 は同 CSV および第 3 回日本語報告書の値を照

合した。Drive 上 checkpoint の hash は本論文作成時に再計算しておらず、未検証の値は記載しない。checkpoint と complete metadata の正本は第 3 回 run folder を参照する。

# 参考文献


[1] D. Eigen, C. Puhrsch, and R. Fergus, ”Depth Map Prediction from a Single Image using a Multi-Scale Deep Network,” NeurIPS 27, 2014. arXiv:1406.2283.

[2] A. Dosovitskiy et al., ”An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale,” ICLR, 2021. arXiv:2010.11929.

[3] R. Ranftl, A. Bochkovskiy, and V. Koltun, ”Vision Transformers for Dense Prediction,” ICCV, 2021. arXiv:2103.13413.

[4] M. Oquab et al., ”DINOv2: Learning Robust Visual Features without Supervision,” TMLR, 2024. arXiv:2304.07193.

[5] L. Yang et al., ”Depth Anything V2,” NeurIPS 37, 2024, pp. 21875–21911. arXiv:2406.09414.

[6] I. Loshchilov and F. Hutter, ”Decoupled Weight Decay Regularization,” ICLR, 2019. arXiv:1711.05101.

[7] J. Zhou et al., ”UAV3DCrop: Benchmarking 3D Reconstruction in Repeated Multi-Angle UAV Crop Surveys,” arXiv:2608.06404, 2026. Preprint.

[8] L. P. Magar et al., ”Plant height measurement using UAV-based aerial RGB and LiDAR images in soybean,” Frontiers in Plant Science, 16, 1488760, 2025. doi:10.3389/fpls.2025.1488760.