

Depth Anything V2 予備実験を理解するための解説

卒業研究用講義ノート

2026 年 9 月

重要

この冊子は、既存の予備実験を自分で説明できるようにするための解説である。見た目がきれいな depth map と、物理的に正しい高さは別物である。今回の中心的な結論は、Depth Anything V2 を稲画像へ適用できたことと、稲高を高精度に測れたことを混同しないことである。

目次

1	この研究で最終的にやりたいこと	3
2	そもそも depth とは何か	3
3	Relative depth と Metric depth	3
4	なぜいきなり稲で評価しなかったのか	3
5	KITTI で何を確認したか	4
6	ETH3D で何を確認したか	4
7	LUMS 稲 UAV で何が分かったか	5
8	UAV3DCrop が重要だった理由	6
9	Metric depth の大きな失敗	6
10	「でも local MAE は 5 cm だった」の罨	6
11	相関と slope	7
12	Sign agreement	7

13	実際の稲で調べた AirMeasurer	7
14	AirMeasurer の結果	8
15	今回の結果を一言で言うと	8
16	何が問題なのか	8
17	卒業研究では何をすればよいか	9
18	よくある誤解	9
18.1	誤解 1: Depth map が綺麗だから正しい	9
18.2	誤解 2: MAE が 5 cm だから高さを 5 cm 精度で測れる	10
18.3	誤解 3: Relative depth は meter 単位である	10
18.4	誤解 4: Metric depth ならどんな画像でも meter 単位で正しい	10
18.5	誤解 5: Correlation が高ければ絶対値も正しい	10
18.6	誤解 6: Scale+shift 後の MAE が良ければ RGB だけでその精度が出る	10
18.7	誤解 7: Orthomosaic を通常の camera image と同じように扱える	10
19	用語集	10
20	まとめ	11

1 この研究で最終的にやりたいこと

最終的には、次の流れを実現したい。

UAV RGB 画像 → Depth Anything V2 → 深度情報 → 地面と稲冠の分離 → 稲の高さ推定 → 3D 復元

ここでいう稲の高さは、カメラからの距離ではなく、地面から稲冠までの高さである。カメラが斜めを向いていたり、地面が傾いていたり、地面が見えなかったりすると、単純な depth 差は高さにならない。

2 そもそも depth とは何か

depth は、画像中の各 pixel がカメラからどの程度離れているかを表す値である。例えば机の上に手前のコップと奥の本があるとき、手前のコップの方がカメラに近く、奥の本の方が遠い。この距離を画像全体について pixel ごとに並べたものが depth map である。

ただし、depth map の色は見やすくするための表示にすぎない。赤い pixel が本当に 5 m、青い pixel が本当に 2 m という意味とは限らない。元の数値と GT を比較して初めて正しさを評価できる。

3 Relative depth と Metric depth

relative depth は、A と B のどちらが近いのか、どこが前後しているかを表す。「A は B より近い」は分かるが、「A はカメラから 5.2 m」とは限らない。

metric depth は「A は 5.2 m」のように物理単位で距離を出すことを目指す。しかし、metric モデルも学習した画像の種類に依存する。道路で学習したモデルを稲の俯瞰画像に使えば、数値の全体がずれる domain shift が起きることがある。

注意

今回の relative model は `depth-anything/Depth-Anything-V2-Small-hf`、屋外 metric model は `depth-anything/Depth-Anything-V2-Metric-Outdoor-Small-hf` である。metric という名前だけで、どの画像でも正しいメートル値になるわけではない。

4 なぜいきなり稲で評価しなかったのか

稲画像にモデルをかけるだけなら、出力画像を作ることはできる。しかし、その出力が正しいかを言うには、同じ pixel の正解 depth または高さが必要である。そこで、まず GT が整備されたデータセットで段階的に確認した。

一般画像 → KITTI → ETH3D → LUMS → UAV3DCrop → AirMeasurer




図 1: KITTI の GT と予測の関係。

この順番は、動作確認、一般 metric 評価、3D 化、実稲への適用、UAV 作物 GT 評価、rice canopy height 比較という意味を持つ。

5 KITTI で何を確認したか

KITTI は道路を走る車から撮った RGB 画像とレーザー由来の depth を持つ。GT の uint16 値を 256 で割るとメートルになる。50 画像を評価し、pooled 結果は MAE 2.5921 m、RMSE 5.4692 m、AbsRel 0.1282 であった。

距離帯を見ると、0–10 m では MAE 0.7002 m、60–80 m では 20.1499 m であった。つまり、遠い対象ほど誤差が大きくなることを確認できた。これは「一般道路画像では動作する」という基準であり、稲画像の精度を保証するものではない。

6 ETH3D で何を確認したか

ETH3D は stereo 画像と calibration を持つ。stereo では、左右画像の同じ点がどれだけずれたかという disparity を使う。おおまかには

$$depth \approx \frac{\text{焦点距離} \times \text{stereo baseline}}{\text{disparity}} \quad (1)$$

であり、正確には calibration 補正と単位変換を行う。




図 2: ETH3D の RGB、GT depth、予測 depth。

Figure 2. RGB, relative depth, and outdoor metric depth




図 3: LUMS 稲画像への適用例。

今回は 1 画像を使い、MAE 1.4367 m、RMSE 1.8926 m、AbsRel 0.2105 であった。さらに intrinsics と depth から、各 pixel を 3D 点へ変換した。これが point cloud である。カメラ座標での predicted と GT の対称平均距離は 0.9134 m であった。

7 LUMS 稲 UAV で何が分かったか

LUMS では、実際の稲圃場を撮影した RGB 画像 9 枚に DA2 を適用した。early、middle、late を各 3 画像使い、relative depth、metric depth、vegetation mask を作成した。metric median は約 5.3–6.8 m で、README の撮影高度約 6 m と同じオーダーであった。

しかし、公開された raw RGB frame と DEM の pixel 対応、frame ごとの camera pose、正解 depth が不足していた。したがって、depth map がもっともらしく見えても、正しいとは言えなかった。ground 候補を使った差は canopy-ground depth difference proxy と呼び、稲高とは呼ばなかった。

8 UAV3DCrop が重要だった理由

UAV3DCrop では、UAV crop RGB 画像と、同じ frame に対応する GT depth、camera intrinsics、camera extrinsics がある。初めて同じ pixel 同士を直接比較できた。

使用画像は Wheat 20、Oat 16、Corn 16 の 52 画像で、nadir 26、oblique 26 である。GT は photogrammetry から得られた camera-frame Z-depth であり、地面からの作物高ではない。それでも、UAV 作物画像に対する絶対 depth と局所差分を定量評価できた点が重要である。

9 Metric depth の大きな失敗

UAV3DCrop の raw metric 結果は MAE 約 13.6 m、Bias 約-13.6 m であった。これは、予測が GT より全体に大幅に小さいことを意味する。例えば GT が 15 m なのに予測が 1–2 m なら、誤差は約-13 m になる。

今回分かったこと

metric モデルは、UAV 作物画像に適用できるが、UAV 作物 domain で正しい絶対距離を出すとは確認できなかった。道路画像で動くことと、作物俯瞰画像でメートル精度が出ることは別である。

10 「でも local MAE は 5 cm だった」の罠

local difference では 2 画素の差を比べる。UAV3DCrop の 32 px pair では、GT 差分の中央値が約 1.56 cm だった。多くの pair がほぼ同じ深度なら、何も変化しないと予測しても誤差は小さくなる。

zero baseline とは、すべての pair について「差は 0」と答えるモデルである。今回の値は次の通りであった。

表 1: 32 px local difference の比較。

予測方法	MAE [m]	RMSE [m]
zero baseline	0.040656	0.137579
metric raw	0.053259	0.150960
relative aligned	0.040874	0.135551

relative aligned の 4.1 cm は、zero baseline の 4.07 cm より明確に良くない。したがって、「local MAE が 4 cm だから、高さを 4 cm 精度で測れる」とは言えない。

11 相関と slope

Pearson correlation は、GT が増えると予測も増えるか、という一緒に増減する度合いである。Spearman correlation は数値そのものより順位的一致を見る。

regression slope は、本当の変化量をどの程度の大きさを再現したかを表す。GT で 50 cm の差があるのに、DA2 で 3 cm しか変化しなければ、slope は約 0.06 である。順番は合っている、変化量を強く圧縮している。

UAV3DCrop の relative aligned では、GT 差分 0.5 m 帯の Pearson は 0.5458、sign agreement は 0.8369 であったが、slope は 0.3064 だった。これは「順序を部分的に捉える可能性」と「高さ差を正しい振幅で再現すること」が別であることを示す。

12 Sign agreement

sign agreement は「どちらが近い、どちらが高い」の順序だけを見る。GT で $A - B > 0$ なら A 側が近い、予測でも $A - B > 0$ なら一致である。

この指標は順序の確認には便利だが、差が何 cm あるかは分からない。AirMeasurer の 1.0 m 差分帯では sign agreement 0.9615 だったが、slope は 0.0536 であった。順番は合っている、差の大きさは約 5 % 程度しか再現していない。

13 実際の稲で調べた AirMeasurer

AirMeasurer では rice の orthomosaic と point cloud を使った。orthomosaic は、複数の写真を地図のようにつなげた画像である。point cloud は、空間中の大量の 3D 点である。

点群から、上側の作物表面を DSM、地面の表面を DEM として求める。DSM から DEM を引いたものが CHM である。

$$\begin{array}{l} \text{作物上面: DSM} \\ \downarrow \quad \text{CHM} = \text{DSM} - \text{DEM} \\ \text{地面: DEM} \end{array}$$

今回は LAS に SOR と CSF を適用して簡易的に DSM、DEM、CHM を作成した。CHM の範囲は約 0–1.285 m であった。

注意

orthomosaic は通常の 1 枚のカメラ画像ではない。そのため、orthomosaic に DA2 metric model をかけても、出力を「カメラからの距離」と解釈してはいけない。AirMeasurer では relative output と CHM の形状関係を比較した。




図 4: AirMeasurer の RGB、CHM、DA2 relative。

14 AirMeasurer の結果

DA2 relative と CHM の pixel-level 比較では、Pearson 0.2579、Spearman 0.2098 であった。これは強い対応とは言にくい。CHM を使って scale+shift した診断値は MAE 0.0791 m、RMSE 0.1450 m、 $R^2 = 0.0665$ であった。

一方、全 pixel を CHM の中央値とする constant baseline は MAE 0.0563 m、RMSE 0.1588 m であった。DA2 は RMSE では改善したが、MAE では baseline に負けた。したがって、pixel-level の canopy height prediction 性能が確認されたとは言えない。

local height difference では、GT 差分が 0.1、0.2、0.5、1.0 m と大きくなるほど Pearson と sign agreement は高くなった。しかし slope は 0.0985、0.0698、0.0554、0.0536 であり、差分の振幅は強く圧縮された。

15 今回の結果を一言で言うと

今回分かったこと

Depth Anything V2 は、稲の高低関係を部分的に捉えている可能性はある。しかし、その出力値をそのまま稲高として使える段階ではない。

16 何が問題なのか

- **domain shift:** 学習画像と実際の稲・UAV 画像の種類が違う。
- **canopy:** 葉が重なり、内部の地面が見えない。
- **thin leaves:** 細い葉や葉先は画像上の手がかりが弱い。
- **ground visibility:** 地面が見えないと、稲高の基準を置けない。
- **orthomosaic:** 複数カメラ画像を地図化した画像で、単一カメラの透視画像ではない。
- **MVS error:** photogrammetry の GT にも風、遮蔽、反復模様による誤差がある。




図 5: AirMeasurer の local height difference.

- **camera geometry:** intrinsics と pose がないと pixel を正しい 3D ray へ変換しにくい。
- **scale:** relative depth には物理単位 of scale がない。

17 卒業研究では何をすればよいか

今後は raw UAV frame、camera intrinsics、camera pose、AGL または地面基準、ground plane または DEM、canopy ROI、実測 rice height を揃える必要がある。まず camera ray と ground surface から ground depth を求め、稲冠側の代表値との差を計算する。

relative depth を既知高さで calibration する場合は、calibration に使った plot と評価用の held-out plot を分ける必要がある。同じ plot で scale を決めて同じ plot で評価すると、未知 plot へ使える性能を過大評価する可能性がある。photogrammetry CHM と DA2 を競争させるだけでなく、relative depth に外部 scale を与える方法も研究課題になる。

18 よくある誤解

18.1 誤解 1: Depth map が綺麗だから正しい

色付けは表示である。GT との数値比較が必要である。

18.2 誤解 2: MAE が 5 cm だから高さを 5 cm 精度で測れる

GT 差分の中央値が 1.56 cm で、zero baseline でも MAE が 4 cm になった。MAE だけで高さ精度は言えない。

18.3 誤解 3: Relative depth は meter 単位である

relative output は順序や形状を表す値であり、メートル単位とは限らない。

18.4 誤解 4: Metric depth ならどんな画像でも meter 単位で正しい

metric checkpoint にも学習 domain がある。UAV3DCrop では大きな bias が観測された。

18.5 誤解 5: Correlation が高ければ絶対値も正しい

相関は一緒に増減するかを見る。全体に 1 m ずれていても相関は高くなり得る。

18.6 誤解 6: Scale+shift 後の MAE が良ければ RGB だけでその精度が出る

scale と shift を GT から求めた診断値であり、未校正の推論精度ではない。

18.7 誤解 7: Orthomosaic を通常の camera image と同じように扱える

orthomosaic は地理的に再構成された地図画像であり、単一 camera-frame depth の入力とは異なる。

19 用語集

monocular depth estimation

1 枚の RGB 画像から深度を推定する方法。

relative depth 画像内の前後関係や順位を表す深度。

metric depth メートルなど物理単位を意図した深度。

depth map pixel ごとの depth 値を並べた画像。

point cloud 3D 座標を持つ点の集合。

SfM 複数画像からカメラ姿勢と 3D 構造を推定する方法。

MVS 複数画像から密な 3D 表面を復元する方法。

DEM 地面表面の高さモデル。

DSM 作物や建物を含む上面表面の高さモデル。

CHM DSM から DEM を引いた canopy height model。

orthomosaic 複数画像を地図のようにつないだ画像。

camera intrinsics	焦点距離、主点、歪みなどカメラ内部の値。
camera extrinsics	カメラの位置と姿勢。
MAE	誤差の絶対値の平均。
RMSE	二乗誤差平均の平方根。大きな誤差に敏感。
AbsRel	GT に対する相対的な絶対誤差。
Bias	signed error の平均。系統的なずれ。
Pearson correlation	2 つの値が線形に一緒に増減する度合い。
Spearman correlation	値の順位が一致する度合い。
regression slope	予測された変化量の大きさを表す傾き。
baseline	比較の基準となる単純な予測。
domain shift	学習画像と評価画像の種類が違うこと。
calibration	既知の基準を用いて出力 scale を合わせること。

20 まとめ

今回確認できたのは、DA2 を稲・作物 UAV 画像へ適用できること、raw metric depth に domain bias があること、relative depth が局所順序を部分的に表す可能性があること、そしてその差分振幅が圧縮されることである。次の段階では、raw frame、camera geometry、ground reference、実測稲高を揃え、calibration を含む検証を独立 plot・独立時期で行うべきである。